1. Importation de packages

```
import os
import pandas as pd
import numpy as np
from utils import charger_donnees_api, imputer_na_par_valeur,
tracer_series_temporelles, sauvegarder_donnees_clean, classifier_risque,
predire_risque

from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import GridSearchCV, TimeSeriesSplit

from sklearn.metrics import classification_report, confusion_matrix, f1_score
import seaborn as sns
import matplotlib.pyplot as plt

import joblib

from xgboost import XGBClassifier
```

2. Importation des données

On définit le dossier de données qui n'est créé que s'il n'existe pas encore dans le repertoire de travail.

```
DOSSIER_DONNEES = "data/raw"
os.makedirs(DOSSIER_DONNEES, exist_ok=True)
```

Nous importons ici les données sur les pollens via l'api open-meteo (**air-quality** pour les données sur les pollens et **archives** pour les données météo); nous avons considéré les données sur un an du 1er janvier 2023 au 01 janvier 2024 pour Rennes.

Données Pollen

```
url_pollen = "https://air-quality-api.open-meteo.com/v1/air-quality"

params_pollen = {
```

```
    "latitude": 48.11,
    "longitude": -1.67,
    "hourly": ["birch_pollen", "grass_pollen"],
    "start_date": "2021-01-01",
    "end_date": "2026-04-19"
}

fichier_pollen = os.path.join(DOSSIER_DONNEES, "pollen.csv")


df_pol = charger_donnees_api(
    url=url_pollen,
    params=params_pollen,
    fichier_cache=fichier_pollen,
    force_reload= False
)
```

Données météo

```
url_meteo = "https://archive-api.open-meteo.com/v1/archive"

params_meteo = {
    "latitude": 48.11,
    "longitude": -1.67,
    "hourly": ["temperature_2m", "precipitation", "wind_speed_10m"],
    "start_date": "2021-01-01",
    "end_date": "2026-04-19",
    "timezone": "Europe/Paris"
}

fichier_meteo = os.path.join(DOSSIER_DONNEES, "meteo.csv")


df_met = charger_donnees_api(
    url=url_meteo,
    params=params_meteo,
    fichier_cache=fichier_meteo,
    force_reload= False
)
```

3.Fusion et analyse exploratoire

Pour éviter de travailler sur les bases originales, on va travailler sur les copies de ces bases.

```
df_meteo = df_met.copy()
df_pollen = df_pol.copy()
```

3.1. Fusion des bases

Pour répondre à la thématique, nous devons fusionner les deux bases; Mais avant toute fusion, il faut vérifier la structure des deux bases et surtout explorer la clé de fusion qui ici est la date. Ci-dessous, un aperçu des deux bases:

```
pd.concat(
    [df_pollen.head(), df_meteo.head()],
    axis=1,
    keys=["Pollen", "Meteo"]
)
```

	Pollen			Meteo			
	date	birch_pollen	grass_pollen	date	temperature_2m	precipitation	wind_speed_10m
0	2021-01-01 00:00:00	0.0	0.0	2021-01-01 00:00:00	−0.4	0.0	2.9
1	2021-01-01 01:00:00	0.0	0.0	2021-01-01 01:00:00	−1.4	0.0	2.1
2	2021-01-01 02:00:00	0.0	0.0	2021-01-01 02:00:00	−1.9	0.0	3.6
3	2021-01-01 03:00:00	0.0	0.0	2021-01-01 03:00:00	−2.5	0.0	2.3
4	2021-01-01 04:00:00	0.0	0.0	2021-01-01 04:00:00	−2.5	0.0	4.3

Pour faciliter la lisibilité et la manipulation des variables, il est nécessaire de les renommer.

```
df_pollen = df_pollen.rename(columns={
    "birch_pollen": "pollen_bouleau",
    "grass_pollen": "pollen_graminees"
})

df_meteo = df_meteo.rename(columns={
    "temperature_2m": "temperature",
    "precipitation": "precipitations",
    "wind_speed_10m": "vitesse_vent"
})
```

```
pd.concat(
    [df_pollen.head(), df_meteo.head()],
    axis=1,
    keys=["Pollen", "Meteo"]
)
```

	Pollen			Meteo			
	date	pollen_boulepo	pollen_graminées	date	tempera-ture	precipita-tions	vitesse_vent
0	2021-01-01 00:00:00	0.0	0.0	2021-01-01 00:00:00	−0.4	0.0	2.9
1	2021-01-01 01:00:00	0.0	0.0	2021-01-01 01:00:00	−1.4	0.0	2.1
2	2021-01-01 02:00:00	0.0	0.0	2021-01-01 02:00:00	−1.9	0.0	3.6
3	2021-01-01 03:00:00	0.0	0.0	2021-01-01 03:00:00	−2.5	0.0	2.3
4	2021-01-01 04:00:00	0.0	0.0	2021-01-01 04:00:00	−2.5	0.0	4.3

Afin de garantir l'intégrité de nos deux bases qui sont temporelles, nous vérifions la régularité du pas de temps via le calcul des différences successives (.diff()). Cette étape confirme la continuité des observations horaires et l'absence de dates manquantes.

```
pd.concat(
                                [df_pollen["date"].diff().value_counts().head(),
df_meteo["date"].diff().value_counts().head()],
    axis=1,
    keys=["Pollen", "Meteo"]
)
```

	Pollen	Meteo
date		
0 days 01:00:00	46439	46439

Vérifions que les périodes se chevauchent pour les deux bases. ça devrait être le cas au regard des paramètres d'importation mais la vérification en vaut la peine.

```
pd.DataFrame({
    "Pollen": [df_pollen["date"].min(), df_pollen["date"].max()],
    "Meteo": [df_meteo["date"].min(), df_meteo["date"].max()]
}, index=["Min date", "Max date"])
```

	Pollen	Meteo
Min date	2021-01-01 00:00:00	2021-01-01 00:00:00
Max date	2026-04-19 23:00:00	2026-04-19 23:00:00

On remarque que les données des deux bases sont sans fuseau attachés, ce qui facilite la fusion locale en prenant la date comme clé de fusion.

```
print(df_meteo["date"].dt.tz)
print(df_pollen["date"].dt.tz)
```

```
None
None
```

On se rend également compte qu'avant la fusion, il n y a pas de valeur manquante dans la base météo.

```
pd.concat(
    [df_pollen.isnull().sum(), df_meteo.isnull().sum()],
    axis=1,
    keys=["Pollen", "Meteo"]
)
```

	Pollen	Meteo
date	0.0	0.0
pollen_bouleau	12791.0	NaN
pollen_graminees	10559.0	NaN
temperature	NaN	0.0
precipitations	NaN	0.0
vitesse_vent	NaN	0.0

Fusion des deux bases Fusion des deux bases: avec toutes les vérifications qui viennent d'être faites sur la variable date qui est la clé primaire ici, on peut fusionner simplement avec un inner_join (correspondances exactes)

```
df_pollen_meteo = pd.merge(df_pollen, df_meteo, on="date", how="inner")

df_pollen_meteo.to_csv("data/raw/df_pollen_meteo_merge.csv")

print(df_pollen_meteo.shape)
df_pollen_meteo.head()
```

```
(46440, 6)
```

	date	pollen_bouleau	pollen_graminees	temperature	precipitations	vitesse_vent
0	2021-01-01 00:00:00	0.0	0.0	−0.4	0.0	2.9
1	2021-01-01 01:00:00	0.0	0.0	−1.4	0.0	2.1
2	2021-01-01 02:00:00	0.0	0.0	−1.9	0.0	3.6
3	2021-01-01 03:00:00	0.0	0.0	−2.5	0.0	2.3
4	2021-01-01 04:00:00	0.0	0.0	−2.5	0.0	4.3

3.2. Exploration et traitement de la base d'étude

```
print("\n--- Informations détaillées (Check-up complet) ---")
df_pollen_meteo.info()
```

```

--- Informations détaillées (Check-up complet) ---
<class 'pandas.DataFrame'>
RangeIndex: 46440 entries, 0 to 46439
Data columns (total 6 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   date              46440 non-null  datetime64[us]
 1   pollen_bouleau    33649 non-null  float64
 2   pollen_graminees  35881 non-null  float64
 3   temperature       46440 non-null  float64
 4   precipitations    46440 non-null  float64
```

```
 5   vitesse_vent      46440 non-null  float64
dtypes: datetime64[us](1), float64(5)
memory usage: 2.1 MB
```

```
df_pollen_meteo.isnull().sum()
```

```
date                    0
pollen_bouleau      12791
pollen_graminees    10559
temperature             0
precipitations          0
vitesse_vent            0
dtype: int64
```

Interprétation des valeurs manquantes

L'analyse des périodes manquantes montre qu'elles correspondent en réalité à des **phases biologiques naturelles** et non à des erreurs de collecte de données.

Pour le pollen de bouleau, les données sont absentes de janvier à fin février, ce qui correspond à une période de dormance. Elles sont présentes de mars à début août, période de pollinisation, puis redeviennent absentes à partir d'août jusqu'au 20 novembre, marquant la fin de la saison.

Pour les graminées, les données sont également absentes en hiver (janvier-février), présentes de mars à début septembre, ce qui reflète une saison de pollinisation plus longue, puis absentes à nouveau à partir de septembre jusqu'au 20 novembre.

Ces résultats sont cohérents avec les connaissances biologiques et confirment que les valeurs manquantes ne sont pas problématiques, mais traduisent simplement l'absence de pollen hors saison. Cela nous emmene donc à imputer ces valeurs manquantes par des 0.

```
from IPython.display import display, HTML
from utils import identifier_plages_manquantes

# Bouleau
display(HTML("<b>Périodes manquantes pour le Pollen de bouleau</b>"))
plages_bouleau         =         identifier_plages_manquantes(df_pollen_meteo,
'pollen_bouleau')
display(plages_bouleau)

# Graminées
display(HTML("<b>Périodes manquantes pour les graminées</b>"))
plages_graminees        =        identifier_plages_manquantes(df_pollen_meteo,
```

```
'pollen_graminees')
display(plages_graminees)
```

```
<IPython.core.display.HTML object>
```

```
--- Analyse : pollen_bouleau ---
Total NaN dans la colonne : 12791
Total identifié par blocs : 12791
Vérification : OK (Tous les NaN sont comptabilisés).
```

	date_debut	date_fin	heures_manquantes	total_cumule_manquant
0	2021-08-01 00:00:00	2022-02-28 23:00:00	5088	5088
1	2022-08-01 00:00:00	2023-02-28 23:00:00	5088	10176
2	2023-08-04 01:00:00	2023-11-20 23:00:00	2615	12791

```
<IPython.core.display.HTML object>
```

```
--- Analyse : pollen_graminees ---
Total NaN dans la colonne : 10559
Total identifié par blocs : 10559
Vérification : OK (Tous les NaN sont comptabilisés).
```

	date_debut	date_fin	heures_manquantes	total_cumule_manquant
0	2021-09-01 00:00:00	2022-02-28 23:00:00	4344	4344
1	2022-09-01 00:00:00	2023-02-28 23:00:00	4344	8688
2	2023-09-04 01:00:00	2023-11-20 23:00:00	1871	10559

Bien qu'après le 20 novembre 2023, les données ne soient pas manquantes pour ces deux variables de pollen, les valeurs qu'elles prennent sont nulles comme on peut le voir sur les graphiques plus bas; Ce même comportement est observé pour les mêmes périodes des années 2024 et 2025; ce qui est normal vu que la période novembre-decembre n'est pas leur saison.

```
# Définition de la borne temporelle (juste après le dernier NaN)
date_reprise = "2023-11-20 23:00:00"

# Création du sous-ensemble de données pour la fin d'année
df_fin_annee = df_pollen_meteo[df_pollen_meteo['date'] > date_reprise].copy()
```

```
# Calcul des statistiques pour se rassurer
stats_fin_annee = df_fin_annee[['pollen_bouleau', 'pollen_graminees']].agg(['max', 'min','mean', 'sum', 'count'])

print(f"--- Analyse de la période : du {df_fin_annee['date'].min()} au {df_fin_annee['date'].max()} ---")
print(f"Nombre total d'heures analysées : {len(df_fin_annee)}")
print("\nStatistiques des pollens sur cette période :")
display(stats_fin_annee)
```

```
--- Analyse de la période : du 2023-11-21 00:00:00 au 2026-04-19 23:00:00 ---
Nombre total d'heures analysées : 21144

Statistiques des pollens sur cette période :
```

	pollen_bouleau	pollen_graminees
max	344.90000	136.500000
min	0.00000	0.000000
mean	2.40472	4.525435
sum	50845.40000	95685.800000
count	21144.00000	21144.000000

Imputation des valeurs manquantes par 0

```
colonnes_pollen = ['pollen_bouleau', 'pollen_graminees']

df_pollen_meteo_clean = imputer_na_par_valeur(df_pollen_meteo, colonnes_pollen)


# 3. Vérification finale
print("Nombre de valeurs manquantes après imputation :")
print(df_pollen_meteo_clean[colonnes_pollen].isna().sum())
```

```
Nombre de valeurs manquantes après imputation :
pollen_bouleau      0
pollen_graminees    0
dtype: int64
```

```
sauvegarder_donnees_clean(
    df=df_pollen_meteo_clean,
    nom_fichier="df_pollen_meteo_clean.csv",
    dossier="data/clean"
)
```

```
Données sauvegardées dans : data/clean/df_pollen_meteo_clean.csv
```

Variables polliniques — Bouleau & Graminées

Saisonnalité stricte et récurrente

Les deux espèces présentent une phénologie (cycles de vie selon le climat et la saison) remarquablement stable : le pic de bouleau se produit chaque année en mars–avril, immédiatement suivi du pic de graminées en mai–juillet. Cette régularité calendaire constitue un signal prédictif fort — la variable `jour_de_l_année` (avec un encodage sinusoïdal) sera vraisemblablement un prédicteur très discriminant du modèle.

Variabilité inter-annuelle marquée

L'intensité des pics fluctue fortement d'une année à l'autre, indépendamment de leur date d'occurrence. Le pic de bouleau de 2021 dépasse 500 grains/m³, tandis que celui de 2024 plafonne à ~150 grains/m³ — soit un facteur ×3. Cette variance inter-annuelle suggère que des conditions météorologiques spécifiques à chaque saison (températures hivernales, gel tardif, pluviométrie printanière) modulerait l'intensité de la saison pollinique. Le modèle devra capturer ces interactions.

Distribution fortement asymétrique ("zero-inflated")

Les concentrations sont nulles ou quasi-nulles sur environ 75–80 % de l'année. La cible est donc déséquilibrée par construction : les pics sont rares, brefs et intenses. En classification, on devra éventuellement faire un rééquilibrage de classes (SMOTE ou `class_weight='balanced'`) ;

Variables météorologiques

Température *(signal principal)*

La courbe sinusoïdale annuelle coïncide visuellement avec les fenêtres d'émission pollinique : les pics ne semblent se déclencher qu'au-dessus d'un seuil de douceur printanière.

Précipitations *(effet "lavage atmosphérique")*

Les précipitations sont très sporadiques (distribution Poisson-like, avec des pics à 12–14 mm). Leur effet principal attendu est un lessivage rapide des particules en suspension : une pluie significative fait chuter par hypothèse les concentrations dans les 24–48 h. Ce mécanisme justifierait l'inclusion d'un **lag de 1–2 jours** sur les précipitations, en plus de la valeur courante.

Vitesse du vent *(disperseur ambivalent)*

Le signal est bruité et haute-fréquence (variabilité journalière importante à Rennes, site côtier). L'effet sur le pollen est non-linéaire : un vent modéré favoriserait la dispersion et augmente les concentrations locales, tandis qu'un vent fort tend à diluer et à déplacer les masses d'air. Une

transformation (ex. `log(vent + 1)`) ou une discrétisation en classes (calme / modéré / fort) pourra être évaluée lors du feature engineering.

Synthèse — implications pour la modélisation
Les données seront agrégées pour avoir des données journalières afin garantir un minimum de stabilité.

Observation	Action technique
Saisonnalité forte	Inclure`jour_de_lannee` comme features
Variabilité inter-annuelle	Ajouter lags météo (J-7, J-14) et rolling means
Distribution zero-inflated	Rééquilibrage + métrique adaptée (F1-macro, MAE)
Effet retardé pluie/vent	Features laggées à J-1 et J-2
Non-linéarité vent	Transformation log ou discrétisation

```
tracer_series_temporelles(
    df=df_pollen_meteo_clean,
    variables=[
        "pollen_bouleau",
        "pollen_graminees",
        "temperature",
        "precipitations",
        "vitesse_vent"
    ],
    titres={
        "pollen_bouleau": "Évolution du pollen de bouleau",
        "pollen_graminees": "Évolution du pollen de graminées",
        "temperature": "Évolution de la température",
        "precipitations": "Évolution des précipitations",
        "vitesse_vent": "Évolution de la vitesse du vent"
    },
    ylabels={
        "pollen_bouleau": "Concentration pollen",
        "pollen_graminees": "Concentration pollen",
        "temperature": "Température (°C)",
        "precipitations": "Précipitations (mm)",
        "vitesse_vent": "Vitesse du vent (km/h)"
    },
    couleurs={
        "pollen_bouleau": "green",
        "pollen_graminees": "orange",
```

```
        "temperature": "red",
        "precipitations": "blue",
        "vitesse_vent": "purple"
    }
)
```

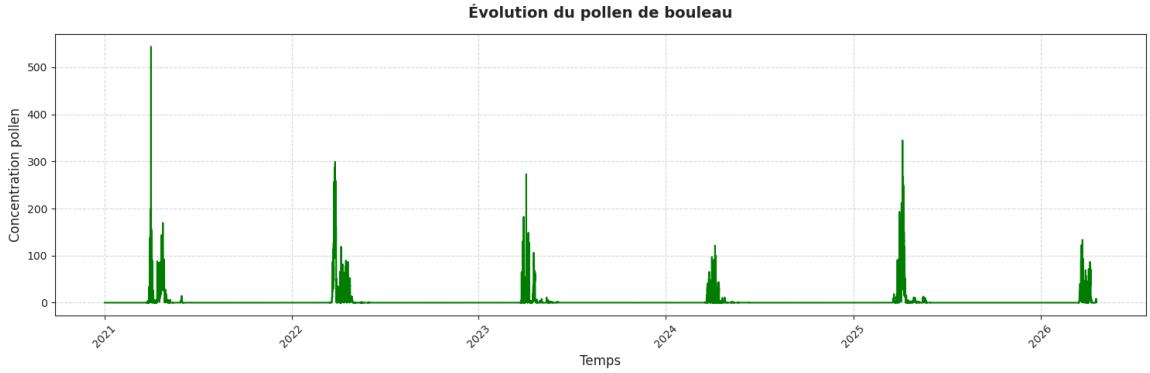

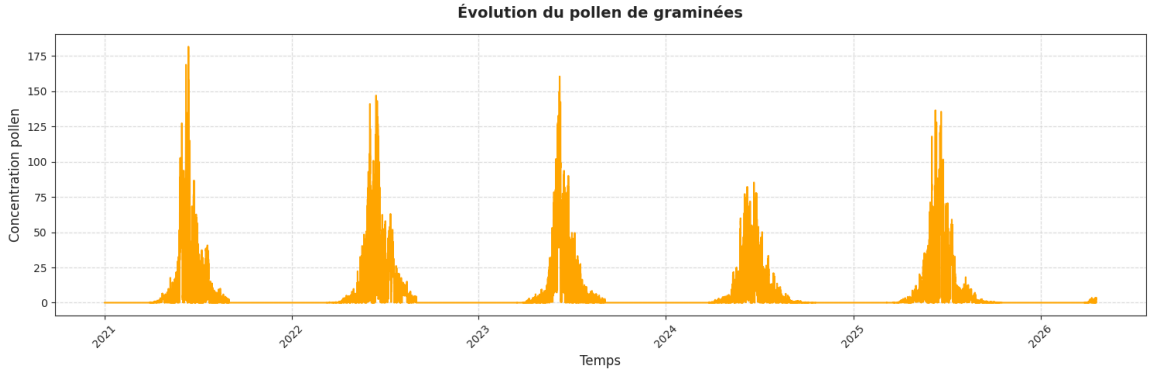

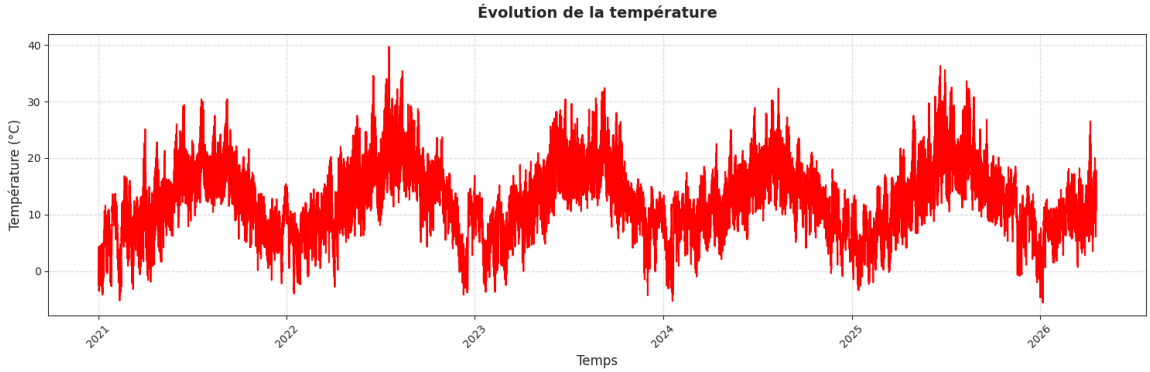

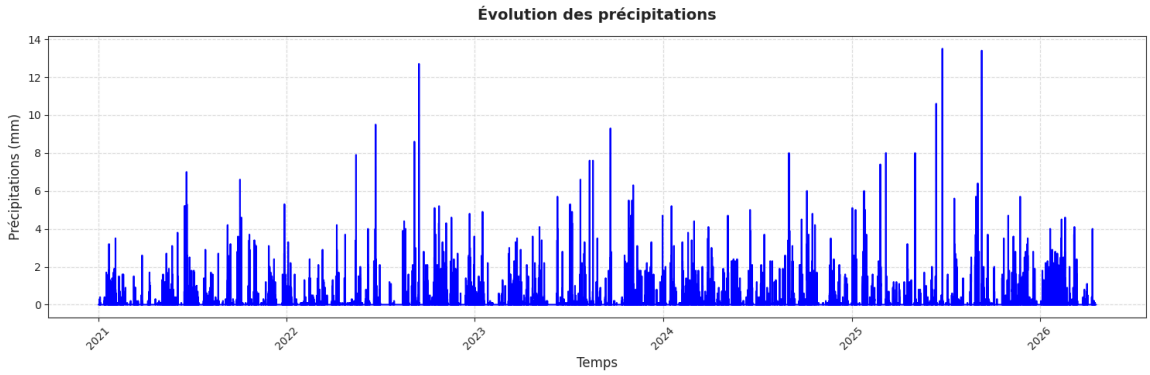

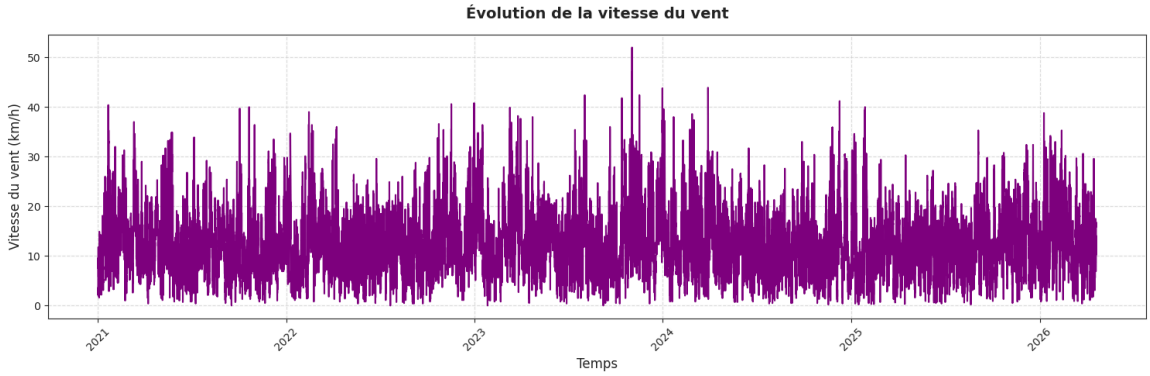

Creation des données journalières

```
# Agrégation journalière
df_jour = df_pollen_meteo_clean.resample('D', on='date').agg(
    pollen_bouleau=('pollen_bouleau', 'max'),
    pollen_graminees=('pollen_graminees', 'max'),
    temperature=('temperature', 'mean'),
    precipitations=('precipitations', 'sum'),
    vitesse_vent=('vitesse_vent', 'mean')
).reset_index()

sauvegarder_donnees_clean(
    df=df_jour,
    nom_fichier="df_pollen_meteo_jour.csv",
    dossier="data/clean"
)

print(df_jour.shape)
df_jour.head()
```

```
Données sauvegardées dans : data/clean/df_pollen_meteo_jour.csv
(1935, 6)
```

	date	pollen_bouleau	pollen_graminees	temperature	precipitations	vitesse_vent
0	2021-01-01	0.0	0.0	−0.233333	0.0	7.483333
1	2021-01-02	0.0	0.0	−0.258333	0.0	5.045833
2	2021-01-03	0.0	0.0	1.225000	1.7	7.883333
3	2021-01-04	0.0	0.0	1.129167	1.4	9.716667
4	2021-01-05	0.0	0.0	1.812500	0.1	10.504167

3.3. Feature engeneering

Pour des raisons justifiées ci dessous, les variables à inclure dans notre modèle sont se présentent comme suit:

Température — le déclencheur principal

La floraison ne réagit pas à la température du jour même, mais à une accumulation de chaleur sur plusieurs jours. Les recherches en phénologie végétale montrent trois horizons pertinents :

Feature	Fenêtre	Justification biologique
temp_lag1	J-1	Réaction immédiate de dispersion (un vent chaud peut entrainer la libération de pollen)
temp_roll7	moy J-7⟶J-1	une “Semaine douce” peut être un signal de floraison imminent
temp_roll14	moy J-14⟶J-1	Une accumulation thermique lente peut déclencher les premières fleurs

Précipitations — l’effet lavage

La pluie agit très vite (24–48h) en lavant les particules de l’air. Au-delà de 3 jours, l’effet deviendrait négligeable.

Feature	Fenêtre	Justification
precip_lag1	J-1	Effet du lavage immédiatement le lendemain
precip_lag2	J-2	Effet résiduel du lavage 48h après

Feature	Fenêtre	Justification
precip_roll7	somme J-7⟶J-1	une période sèche prolongée entrainerait une accumulation de pollen

Pour la pluie journalière, on prend une **somme (cumul)**, pas une moyenne — ce qui compte, c'est la quantité totale tombée.

Vent — le transporteur

Le vent influence la concentration locale mais son effet est immédiat, pas cumulatif.

Feature	Fenêtre	Justification
wind_lag1	J-1	Une dispersion la veille affecte ce qu'on mesure aujourd'hui
wind_roll7	moy J-7⟶J-1	Un vent fort le long de la semaine pourrait réduire la concentration de pollen dans un site côtier comme Rennes

```
# ═══════════════════════════════════════════════════════
# 1. FEATURES TEMPORELLES
# ═══════════════════════════════════════════════════════

df_jour["jour_de_annee"] = df_jour["date"].dt.dayofyear
df_jour["mois"]          = df_jour["date"].dt.month
df_jour["annee"]         = df_jour["date"].dt.year
df_jour["saison"]        = df_jour["mois"].map({
    12:0, 1:0, 2:0,
     3:1, 4:1, 5:1,
     6:2, 7:2, 8:2,
     9:3,10:3,11:3
})

# Encodage cyclique
df_jour["jour_sin"] = np.sin(2 * np.pi * df_jour["jour_de_annee"] / 365)
df_jour["jour_cos"] = np.cos(2 * np.pi * df_jour["jour_de_annee"] / 365)
df_jour["mois_sin"] = np.sin(2 * np.pi * df_jour["mois"] / 12)
df_jour["mois_cos"] = np.cos(2 * np.pi * df_jour["mois"] / 12)

# ═══════════════════════════════════════════════════════
```

```python
# 2. FEATURES MÉTÉO LAGGÉES ET GLISSANTES
# ═══════════════════════════════════════════════════════════

df_jour["temp_lag1"]   = df_jour["temperature"].shift(1)
df_jour["temp_roll7"]  = df_jour["temperature"].shift(1).rolling(7).mean()

df_jour["precip_lag1"]  = df_jour["precipitations"].shift(1)
df_jour["precip_lag2"]  = df_jour["precipitations"].shift(2)
df_jour["precip_roll7"] = df_jour["precipitations"].shift(1).rolling(7).sum()

df_jour["vitesse_vent_lag1"]  = df_jour["vitesse_vent"].shift(1)
df_jour["vitesse_vent_roll7"]
= df_jour["vitesse_vent"].shift(1).rolling(7).mean()

# ═══════════════════════════════════════════════════════════
# 3. DEGRÉS-JOURS CUMULÉS (GDD)
# ═══════════════════════════════════════════════════════════

df_jour["gdd_daily"] = (df_jour["temperature"] - 5).clip(lower=0)
df_jour["gdd_cumul"] = df_jour.groupby("annee")["gdd_daily"].cumsum()

# ═══════════════════════════════════════════════════════════
# 4. LAGS POLLEN (features)
# ═══════════════════════════════════════════════════════════

for col in ['pollen_bouleau', 'pollen_graminees']:
    for lag in [1, 2, 3]:
        df_jour[f'{col}_lag{lag}'] = df_jour[col].shift(lag)
    df_jour[f'{col}_moy3j'] = df_jour[col].shift(1).rolling(3).mean()

# ═══════════════════════════════════════════════════════════
# 5. VARIABLE CIBLE
# ═══════════════════════════════════════════════════════════

df_jour['risque_bouleau_j1']
= df_jour['pollen_bouleau'].apply(classifier_risque).shift(-1)
df_jour['risque_graminees_j1']
= df_jour['pollen_graminees'].apply(classifier_risque).shift(-1)

# ═══════════════════════════════════════════════════════════
# 6. NETTOYAGE
# ═══════════════════════════════════════════════════════════
```

```
df_jour_modele = df_jour.dropna().reset_index(drop=True)

print(f"Shape final : {df_jour_modele.shape}")
print(f"\nDistribution - Bouleau :")
print(df_jour_modele['risque_bouleau_j1'].value_counts())
print(f"\nDistribution - Graminées :")
print(df_jour_modele['risque_graminees_j1'].value_counts())
```

```
Shape final : (1927, 33)

Distribution - Bouleau :
risque_bouleau_j1
0.0    1809
1.0      60
2.0      58
Name: count, dtype: int64

Distribution - Graminées :
risque_graminees_j1
0.0    1672
1.0     188
2.0      67
Name: count, dtype: int64
```

```
# Sauvegarde optionnelle pour réutilisation
sauvegarder_donnees_clean(
    df=df_jour_modele,
    nom_fichier="df_jour_modele.csv",
    dossier="data/clean"
)
```

```
Données sauvegardées dans : data/clean/df_jour_modele.csv
```

3.4 Définition des variables pour la modélisation

```
features = [
    # Temporelles
    'jour_sin', 'jour_cos', 'mois_sin', 'mois_cos', 'saison', 'annee',
    # Température
    'temp_lag1', 'temp_roll7', 'gdd_cumul',
```

```
    # Précipitations
    'precip_lag1', 'precip_lag2', 'precip_roll7',
    # Vent
    'vitesse_vent_lag1', 'vitesse_vent_roll7',
    # Lags pollen
    'pollen_bouleau_lag1', 'pollen_bouleau_lag2', 'pollen_bouleau_lag3',
    'pollen_bouleau_moy3j',
    'pollen_graminees_lag1', 'pollen_graminees_lag2', 'pollen_graminees_lag3',
    'pollen_graminees_moy3j'
]

features_meteo = [
    'jour_sin', 'jour_cos', 'mois_sin', 'mois_cos', 'saison', 'annee',
    'temp_lag1', 'temp_roll7', 'gdd_cumul',
    'precip_lag1', 'precip_lag2', 'precip_roll7',
    'vitesse_vent_lag1', 'vitesse_vent_roll7'
]

print("Features complètes :", len(features))
print("Features météo :", len(features_meteo))
```

```
Features complètes : 22
Features météo : 14
```

4. Modélisation

4.1 Préparation des données

4.1.1 Déséquilibre des classes

La distribution des classes révèle un fort déséquilibre, avec une très forte prédominance de la classe 0 (absence de pic ou de risque faible) pour les deux taxons. Afin de comprendre l'origine de ce déséquilibre et son impact potentiel sur le modèle, nous avons exploré deux contextes temporels distincts :

- un apprentissage sur toute l'année, incluant notamment les périodes hivernales où la concentration pollinique est naturellement très faible ou nulle ;
- un apprentissage restreint à la saison pollinique, c'est-à-dire les périodes où l'on attend a priori des épisodes à risque (par exemple, mars à juillet pour le bouleau et mai à septembre pour les graminées).

Les proportions observées sont les suivantes :

Type	Toute l'année	Saison pollinique
Bouleau classe 0	94%	87%
Graminées classe 0	85%	66%

Le filtrage sur la saison pollinique améliore légèrement l'équilibre pour les graminées, mais reste insuffisant pour le bouleau, où la classe 0 demeure très majoritaire. Étant donné que notre objectif est de développer un modèle exploitable sur l'ensemble de l'année, nous avons donc choisi de conserver toutes les données, afin de préserver la dynamique réelle de la présence pollinique au cours du cycle saisonnier.

Le déséquilibre est donc traité au niveau de l'apprentissage en utilisant `class_weight='balanced'`, ce qui permet de diminuer l'influence de la classe majoritaire. Par ailleurs, nous privilégions des métriques adaptées comme le **F1-score macro** plutôt que l'accuracy seule, afin de mieux apprécier la performance sur les classes minoritaires correspondant aux pics de risque.

```
print("Distribution - Bouleau :")
print(df_jour_modele['risque_bouleau_j1'].value_counts())
print("\nDistribution - Graminées :")
print(df_jour_modele['risque_graminees_j1'].value_counts())
```

```
Distribution - Bouleau :
risque_bouleau_j1
0.0    1809
1.0      60
2.0      58
Name: count, dtype: int64

Distribution - Graminées :
risque_graminees_j1
0.0    1672
1.0     188
2.0      67
Name: count, dtype: int64
```

4.1.2 Split temporel train/test

Contrairement à un split aléatoire classique, nous respectons l'ordre chronologique des données, conformément aux bonnes pratiques pour les séries temporelles. Le modèle est entraîné sur la période 2021–2024 et évalué sur la période 2025–2026 (avril), de manière à simuler une utilisation prospective dans un contexte opérationnel de prévision pollinique.

```
train = df_jour_modele[df_jour_modele['date'].dt.year <= 2024]
test = df_jour_modele[df_jour_modele['date'].dt.year >= 2025]

X_train = train[features]
X_test = test[features]

y_train_bouleau = train['risque_bouleau_j1'].astype(int)
y_test_bouleau = test['risque_bouleau_j1'].astype(int)

y_train_graminees = train['risque_graminees_j1'].astype(int)
y_test_graminees = test['risque_graminees_j1'].astype(int)

print("Train :", X_train.shape)
print("Test :", X_test.shape)
print("\nAnnées train :", sorted(train['date'].dt.year.unique()))
print("Années test :", sorted(test['date'].dt.year.unique()))
```

```
Train : (1454, 22)
Test : (473, 22)

Années train : [np.int32(2021), np.int32(2022), np.int32(2023), np.int32(2024)]
Années test : [np.int32(2025), np.int32(2026)]
```

4.2 Modélisation

4.2.1 Pipeline preprocessing + modèles

Nous construisons un pipeline scikit-learn qui intègre à la fois les étapes de preprocessing et les modèles, afin de garantir une application cohérente aux données d'entraînement et de test. Ce pipeline comprend :

- **StandardScaler** : standardisation des variables continues, nécessaire pour la régression logistique et souvent bénéfique pour d'autres modèles à base de distance.
- **Quatre modèles** : une régression logistique (baseline), un arbre de décision, un Random Forest et un XGBoost, permettant de comparer des méthodes simples, ensemblistes et boostées.
- **GridSearchCV** avec `TimeSeriesSplit` : sélectionne les meilleurs hyperparamètres tout en respectant l'ordre chronologique des données.
- **F1-macro** comme métrique d'évaluation : adapté au déséquilibre des classes, il permet de mieux apprécier la performance sur les classes minoritaires qu'un simple score de précision.

Pipeline avec preprocessing et modèle

```
pipeline = Pipeline([
    ('scaler', StandardScaler()),
```

```
    ('modele', LogisticRegression())
])
```

Grille de paramètres pour les 4 modèles

```
param_grid = [
    {
        'modele': [LogisticRegression(max_iter=1000)],
        'modele__C': [0.1, 1, 10],
        'modele__class_weight': ['balanced']
    },
    {
        'modele': [DecisionTreeClassifier()],
        'modele__max_depth': [5, 10, None],
        'modele__class_weight': ['balanced']
    },
    {
        'modele': [RandomForestClassifier(random_state=42)],
        'modele__n_estimators': [100, 200],
        'modele__max_depth': [3, 5, 10, None],
        'modele__min_samples_leaf': [1, 5, 10],
        'modele__class_weight': ['balanced']
    },
    {
            'modele':  [XGBClassifier(random_state=42,  eval_metric='mlogloss',
verbosity=0)],
        'modele__n_estimators': [100, 200],
        'modele__max_depth': [5, 10],
        'modele__learning_rate': [0.05, 0.1]
    }
]
```

Validation croisée temporelle

```
tscv = TimeSeriesSplit(n_splits=5)
```

4.2.2 Sélection du meilleur modèle - Bouleau

```
grid_search_bouleau = GridSearchCV(
    pipeline,
    param_grid,
    cv=tscv,
    scoring='f1_macro',
```

```
    n_jobs=-1,
    verbose=1
)

grid_search_bouleau.fit(X_train, y_train_bouleau)
```

```
Fitting 5 folds for each of 38 candidates, totalling 190 fits
```

	estimator estimator: estimator object This is assumed to implement the scikit-learn estimator interface. Either estimator needs to provide a ``score`` function, or ``scoring`` must be passed.	Pipeline(step...egression())])
	param_grid param_grid: dict or list of dictionaries Dictionary with parameters names (`str`) as keys and lists of parameter settings to try as values, or a list of such dictionaries, in which case the grids spanned by each dictionary in the list are explored. This enables searching over any sequence of parameter settings.	[{'modele': [LogisticRegre...max_iter=1000)], 'modele__C': [0.1, 1, ...], 'modele__class_weight': ['balanced']}, {'modele': [DecisionTreeClassifier()], 'modele__class_weight': ['balanced'], 'modele__max_depth': [5, 10, ...]}, ...]
	scoring scoring: str, callable, list, tuple or dict, default=None Strategy to evaluate the performance of the cross-vali-	'f1_macro'

	dated model on the test set. If `scoring` represents a single score, one can use: - a single string (see :ref:`scoring_string_names`); - a callable (see :ref:`scoring_callable`) that returns a single value; - `None`, the `estimator`'s :ref:`default evaluation criterion ` is used. If `scoring` represents multiple scores, one can use: - a list or tuple of unique strings; - a callable returning a dictionary where the keys are the metric names and the values are the metric scores; - a dictionary with metric names as keys and callables as values. See :ref:`multimetric_grid_search` for an example.	

	n_jobs n_jobs: int, default=None
	
	Number of jobs to run in parallel.
	``None`` means 1 unless in a :obj:`joblib.parallel_backend`
	context.
	``−1`` means using all processors. See :term:`Glossary `
	for more details.
		−1

	.. versionchanged:: v0.20 `n_jobs` default changed from 1 to None	
	refit refit: bool, str, or callable, default=True Refit an estimator using the best found parameters on the whole dataset. For multiple metric evaluation, this needs to be a `str` denoting the scorer that would be used to find the best parameters for refitting the estimator at the end. Where there are considerations other than maximum score in choosing a best estimator, ``refit`` can be set to a function which returns the selected ``best_index_`` given ``cv_results_``. In that case, the ``best_estimator_`` and ``best_params_`` will be set according to the returned ``best_index_`` while the ``best_score_`` attribute will not be available. The refitted estimator is made available at the ``best_estimator_`` attribute and permits using	True

	``predict`` directly on this ``GridSearchCV`` instance. Also for multiple metric evaluation, the attributes ``best_index_``, ``best_score_`` and ``best_params_`` will only be available if ``refit`` is set and all of them will be determined w.r.t this specific scorer. See ``scoring`` parameter to know more about multiple metric evaluation. See :ref:`sphx_glr_auto_examples_model_selection_plot_grid_search_digits.py` to see how to design a custom selection strategy using a callable via `refit`. See :ref:`this example` for an example of how to use ``refit=callable`` to balance model complexity and cross-validated score. .. versionchanged:: 0.20 Support for callable added.	
	cv cv: int, cross-validation generator or an iterable, default=None Determines the cross-validation splitting strategy.	TimeSeriesSpl… est_size=None)

	Possible inputs for cv are: - None, to use the default 5-fold cross validation, - integer, to specify the number of folds in a `(Stratified)KFold`, - :term:`CV splitter`, - An iterable yielding (train, test) splits as arrays of indices. For integer/None inputs, if the estimator is a classifier and ``y`` is either binary or multiclass, :class:`StratifiedKFold` is used. In all other cases, :class:`KFold` is used. These splitters are instantiated with `shuffle=False` so the splits will be the same across calls. Refer :ref:`User Guide ` for the various cross-validation strategies that can be used here. .. versionchanged:: 0.22 ``cv`` default value if None changed from 3-fold to 5-fold.	
	verbose verbose: int Controls the verbosity: the higher, the more messages. - >1 : the computation time for each fold and parameter candidate is	1

	displayed; - >2 : the score is also displayed; - >3 : the fold and candidate parameter indexes are also displayed together with the starting time of the computation.	
	pre_dispatch pre_dispatch: int, or str, default='2*n_jobs' Controls the number of jobs that get dispatched during parallel execution. Reducing this number can be useful to avoid an explosion of memory consumption when more jobs get dispatched than CPUs can process. This parameter can be: - None, in which case all the jobs are immediately created and spawned. Use this for lightweight and fast-running jobs, to avoid delays due to on-demand spawning of the jobs - An int, giving the exact number of total jobs that are spawned - A str, giving an expression as a function of n_jobs, as in '2*n_jobs'	'2*n_jobs'
	error_score error_score: 'raise' or numeric, default=np.nan Value to assign to the score if	nan

	an error occurs in estimator fitting. If set to 'raise', the error is raised. If a numeric value is given, FitFailedWarning is raised. This parameter does not affect the refit step, which will always raise the error.	
	return_train_score return_train_score: bool, default=False If ``False``, the ``cv_results_`` attribute will not include training scores. Computing training scores is used to get insights on how different parameter settings impact the overfitting/underfitting trade-off. However computing the scores on the training set can be computationally expensive and is not strictly required to select the parameters that yield the best generalization performance. .. versionadded:: 0.19 .. versionchanged:: 0.21 Default value was changed from ``True`` to ``False``	False

	copy copy: bool, default=True	True

	If False, try to avoid a copy and do inplace scaling instead. This is not guaranteed to always work inplace; e.g. if the data is not a NumPy array or scipy.sparse CSR matrix, a copy may still be returned.	
	with_mean with_mean: bool, default=True If True, center the data before scaling. This does not work (and will raise an exception) when attempted on sparse matrices, because centering them entails building a dense matrix which in common use cases is likely to be too large to fit in memory.	True
	with_std with_std: bool, default=True If True, scale the data to unit variance (or equivalently, unit standard deviation).	True

	n_estimators n_estimators: int, default=100 The number of trees in the forest. .. versionchanged:: 0.22 The default value of ``n_estimators`` changed	200

	from 10 to 100 in 0.22.	
	criterion criterion: {"gini", "entropy", "log_loss"}, default="gini" The function to measure the quality of a split. Supported criteria are "gini" for the Gini impurity and "log_loss" and "entropy" both for the Shannon information gain, see :ref:`tree_mathematical_formulation`. Note: This parameter is tree-specific.	'gini'
	max_depth max_depth: int, default=None The maximum depth of the tree. If None, then nodes are expanded until all leaves are pure or until all leaves contain less than min_samples_split samples.	3
	min_samples_split min_samples_split: int or float, default=2 The minimum number of samples required to split an internal node: - If int, then consider `min_samples_split` as the minimum number. - If float, then `min_samples_split` is a fraction and `ceil(min_samples_split * n_samples)` are the minimum	2

	number of samples for each split. .. versionchanged:: 0.18 Added float values for fractions.	
	min_samples_leaf min_samples_leaf: int or float, default=1 The minimum number of samples required to be at a leaf node. A split point at any depth will only be considered if it leaves at least ``min_samples_leaf`` training samples in each of the left and right branches. This may have the effect of smoothing the model, especially in regression. - If int, then consider `min_samples_leaf` as the minimum number. - If float, then `min_samples_leaf` is a fraction and `ceil(min_samples_leaf * n_samples)` are the minimum number of samples for each node. .. versionchanged:: 0.18 Added float values for fractions.	10
	min_weight_fraction_leaf min_weight_fraction_leaf:	0.0

	float, default=0.0 The minimum weighted fraction of the sum total of weights (of all the input samples) required to be at a leaf node. Samples have equal weight when sample_weight is not provided.	
	max_features max_features: {"sqrt", "log2", None}, int or float, default="sqrt" The number of features to consider when looking for the best split: - If int, then consider `max_features` features at each split. - If float, then `max_features` is a fraction and `max(1, int(max_features * n_features_in_))` features are considered at each split. - If "sqrt", then `max_features=sqrt(n_features)`. - If "log2", then `max_features=log2(n_features)`. - If None, then `max_features=n_features`. .. versionchanged:: 1.1 The default of `max_features` changed from `"auto"` to `"sqrt"`. Note: the search for a split does not stop until at least one	'sqrt'

	valid partition of the node samples is found, even if it requires to effectively inspect more than ``max_features`` features.	
	max_leaf_nodes max_leaf_nodes: int, default=None Grow trees with ``max_leaf_nodes`` in best-first fashion. Best nodes are defined as relative reduction in impurity. If None then unlimited number of leaf nodes.	None
	min_impurity_decrease min_impurity_decrease: float, default=0.0 A node will be split if this split induces a decrease of the impurity greater than or equal to this value. The weighted impurity decrease equation is the following:: N_t / N * (impurity - N_t_R / N_t * right_impurity - N_t_L / N_t * left_impurity) where ``N`` is the total number of samples, ``N_t`` is the number of samples at the current node, ``N_t_L`` is the number of samples in the left child, and ``N_t_R`` is	0.0

	the number of samples in the right child. ``N``, ``N_t``, ``N_t_R`` and ``N_t_L`` all refer to the weighted sum, if ``sample_weight`` is passed. .. versionadded:: 0.19	
	bootstrap bootstrap: bool, default=True Whether bootstrap samples are used when building trees. If False, the whole dataset is used to build each tree.	True
	oob_score oob_score: bool or callable, default=False Whether to use out-of-bag samples to estimate the generalization score. By default, :func:`~sklearn.metrics.accuracy_score` is used. Provide a callable with signature `metric(y_true, y_pred)` to use a custom metric. Only available if `bootstrap=True`. For an illustration of out-of-bag (OOB) error estimation, see the example :ref:`sphx_glr_auto_examples_ensemble_plot_ensemble_oob.py`.	False
	n_jobs n_jobs: int, default=None The number of jobs to run in paral-	None

	lel. :meth:`fit`, :meth:`predict`, :meth:`decision_path` and :meth:`apply` are all parallelized over the trees. ``None`` means 1 unless in a :obj:`joblib.parallel_backend` context. ``-1`` means using all processors. See :term:`Glossary ` for more details.	
	random_state random_state: int, RandomState instance or None, default=None Controls both the randomness of the bootstrapping of the samples used when building trees (if ``bootstrap=True``) and the sampling of the features to consider when looking for the best split at each node (if ``max_features < n_features``). See :term:`Glossary ` for details.	42
	verbose verbose: int, default=0 Controls the verbosity when fitting and predicting.	0
	warm_start warm_start: bool, default=False When set to ``True``, reuse the solution of the previous call to fit and add more estimators to the ensemble, otherwise, just	False

	fit a whole new forest. See :term:`Glossary ` and :ref:`tree_ensemble_warm_start` for details.	
	class_weight class_weight: {"balanced", "balanced_subsample"}, dict or list of dicts, default=None Weights associated with classes in the form ``{class_label: weight}``. If not given, all classes are supposed to have weight one. For multi-output problems, a list of dicts can be provided in the same order as the columns of y. Note that for multioutput (including multilabel) weights should be defined for each class of every column in its own dict. For example, for four-class multilabel classification weights should be [{0: 1, 1: 1}, {0: 1, 1: 5}, {0: 1, 1: 1}, {0: 1, 1: 1}] instead of [{1:1}, {2:5}, {3:1}, {4:1}]. The "balanced" mode uses the values of y to automatically adjust weights inversely proportional to class frequencies in the input data as ``n_samples / (n_classes * np.bincount(y))``	'balanced'

	The "balanced_subsample" mode is the same as "balanced" except that weights are computed based on the bootstrap sample for every tree grown. For multi-output, the weights of each column of y will be multiplied. Note that these weights will be multiplied with sample_weight (passed through the fit method) if sample_weight is specified.	
	ccp_alpha ccp_alpha: non-negative float, default=0.0 Complexity parameter used for Minimal Cost-Complexity Pruning. The subtree with the largest cost complexity that is smaller than ``ccp_alpha`` will be chosen. By default, no pruning is performed. See :ref:`minimal_cost_complexity_pruning` for details. See :ref:`sphx_glr_auto_examples_tree_plot_cost_complexity_pruning.py` for an example of such pruning. .. versionadded:: 0.22	0.0
	max_samples max_samples: int or float, default=None If bootstrap is True, the num-	None

	ber of samples to draw from X to train each base estimator. - If None (default), then draw `X.shape[0]` samples. - If int, then draw `max_samples` samples. - If float, then draw `max(round(n_samples * max_samples), 1)` samples. Thus, `max_samples` should be in the interval `(0.0, 1.0]`. .. versionadded:: 0.22	
	monotonic_cst monotonic_cst: array-like of int of shape (n_features), default=None Indicates the monotonicity constraint to enforce on each feature. - 1: monotonic increase - 0: no constraint - −1: monotonic decrease If monotonic_cst is None, no constraints are applied. Monotonicity constraints are not supported for: - multiclass classifications (i.e. when `n_classes > 2`), - multioutput classifications (i.e. when `n_outputs_ > 1`), - classifications trained on data with missing values. The constraints hold over the probability of the positive	None

	class. Read more in the :ref:`User Guide `. .. versionadded:: 1.4	

Comparaison des modèles

```
resultats_bouleau = pd.DataFrame(grid_search_bouleau.cv_results_)
resultats_bouleau['modele'] = resultats_bouleau['param_modele'].apply(
    lambda x: type(x).__name__
)

idx_meilleurs = resultats_bouleau.groupby('modele')['mean_test_score'].idxmax()
resume_bouleau = resultats_bouleau.loc[idx_meilleurs, [
    'modele', 'mean_test_score', 'params'
]].sort_values('mean_test_score', ascending=False).round(3)

for _, row in resume_bouleau.iterrows():
    modele_nom = type(row['params']['modele']).__name__
    params_nets = {k: v for k, v in row['params'].items() if k != 'modele'}
    print(f"\n{modele_nom} (F1-macro: {row['mean_test_score']:.3f})")
    print(params_nets)
```

```
RandomForestClassifier (F1-macro: 0.755)
{'modele__class_weight':       'balanced',       'modele__max_depth':       3,
'modele__min_samples_leaf': 10, 'modele__n_estimators': 200}

DecisionTreeClassifier (F1-macro: 0.683)
{'modele__class_weight': 'balanced', 'modele__max_depth': 5}

XGBClassifier (F1-macro: 0.671)
{'modele__learning_rate': 0.1, 'modele__max_depth': 5, 'modele__n_estimators':
200}

LogisticRegression (F1-macro: 0.657)
{'modele__C': 1, 'modele__class_weight': 'balanced'}
```

4.2.3 Sélection du meilleur modèle - Graminées

```
grid_search_graminees = GridSearchCV(
    pipeline,
    param_grid,
    cv=tscv,
    scoring='f1_macro',
    n_jobs=-1,
    verbose=1
)

grid_search_graminees.fit(X_train, y_train_graminees)
```

```
Fitting 5 folds for each of 38 candidates, totalling 190 fits
```

	estimator estimator: estimator object This is assumed to implement the scikit-learn estimator interface. Either estimator needs to provide a ``score`` function, or ``scoring`` must be passed.	Pipeline(step...egression())])
	param_grid param_grid: dict or list of dictionaries Dictionary with parameters names (`str`) as keys and lists of parameter settings to try as values, or a list of such dictionaries, in which case the grids spanned by each dictionary in the list are explored. This enables searching over any sequence of parameter settings.	[{'modele': [LogisticRegre...max_iter=1000)], 'modele__C': [0.1, 1, ...], 'modele__class_weight': ['balanced']}, {'modele': [DecisionTreeClassifier()], 'modele__class_weight': ['balanced'], 'modele__max_depth': [5, 10, ...]}, ...]

	scoring scoring: str, callable, list, tuple or dict, default=None Strategy to evaluate the performance of the cross-validated model on the test set. If `scoring` represents a single score, one can use: - a single string (see :ref:`scoring_string_names`); - a callable (see :ref:`scoring_callable`) that returns a single value; - `None`, the `estimator`'s :ref:`default evaluation criterion ` is used. If `scoring` represents multiple scores, one can use: - a list or tuple of unique strings; - a callable returning a dictionary where the keys are the metric names and the values are the metric scores; - a dictionary with metric names as keys and callables as values. See :ref:`multimetric_grid_search` for an example.	'f1_macro'
	n_jobs n_jobs: int, default=None Number of jobs to run in parallel.	−1

	``None`` means 1 unless in a :obj:`joblib.parallel_backend` context. ``−1`` means using all processors. See :term:`Glossary ` for more details. .. versionchanged:: v0.20 `n_jobs` default changed from 1 to None	
	refit refit: bool, str, or callable, default=True Refit an estimator using the best found parameters on the whole dataset. For multiple metric evaluation, this needs to be a `str` denoting the scorer that would be used to find the best parameters for refitting the estimator at the end. Where there are considerations other than maximum score in choosing a best estimator, ``refit`` can be set to a function which returns the selected ``best_index_`` given ``cv_results_``. In that case, the ``best_estimator_`` and ``best_params_`` will be set according to the returned ``best_index_`` while the ``best_score_``	True

	attribute will not be available. The refitted estimator is made available at the ``best_estimator_`` attribute and permits using ``predict`` directly on this ``GridSearchCV`` instance. Also for multiple metric evaluation, the attributes ``best_index_``, ``best_score_`` and ``best_params_`` will only be available if ``refit`` is set and all of them will be determined w.r.t this specific scorer. See ``scoring`` parameter to know more about multiple metric evaluation. See :ref:`sphx_glr_auto_examples_model_selection_plot_grid_search_digits.py` to see how to design a custom selection strategy using a callable via `refit`. See :ref:`this example` for an example of how to use ``refit=callable`` to balance model complexity and cross-validated score. .. versionchanged:: 0.20 Support for callable added.	

	cv cv: int, cross-validation generator or an iterable, default=None Determines the cross-validation splitting strategy. Possible inputs for cv are: - None, to use the default 5-fold cross validation, - integer, to specify the number of folds in a `(Stratified)KFold`, - :term:`CV splitter`, - An iterable yielding (train, test) splits as arrays of indices. For integer/None inputs, if the estimator is a classifier and ``y`` is either binary or multiclass, :class:`StratifiedKFold` is used. In all other cases, :class:`KFold` is used. These splitters are instantiated with `shuffle=False` so the splits will be the same across calls. Refer :ref:`User Guide ` for the various cross-validation strategies that can be used here. .. versionchanged:: 0.22 ``cv`` default value if None changed from 3-fold to 5-fold.	TimeSeriesSpl… est_size=None)
	verbose verbose: int	1

	Controls the verbosity: the higher, the more messages. - >1 : the computation time for each fold and parameter candidate is displayed; - >2 : the score is also displayed; - >3 : the fold and candidate parameter indexes are also displayed together with the starting time of the computation.	
	pre_dispatch pre_dispatch: int, or str, default='2*n_jobs' Controls the number of jobs that get dispatched during parallel execution. Reducing this number can be useful to avoid an explosion of memory consumption when more jobs get dispatched than CPUs can process. This parameter can be: - None, in which case all the jobs are immediately created and spawned. Use this for lightweight and fast-running jobs, to avoid delays due to on-demand spawning of the jobs - An int, giving the exact number of total jobs that are spawned - A str, giving an expression	'2*n_jobs'

	as a function of n_jobs, as in '2*n_jobs'	
	error_score error_score: 'raise' or numeric, default=np.nan Value to assign to the score if an error occurs in estimator fitting. If set to 'raise', the error is raised. If a numeric value is given, FitFailedWarning is raised. This parameter does not affect the refit step, which will always raise the error.	nan
	return_train_score return_train_score: bool, default=False If ``False``, the ``cv_results_`` attribute will not include training scores. Computing training scores is used to get insights on how different parameter settings impact the overfitting/underfitting trade-off. However computing the scores on the training set can be computationally expensive and is not strictly required to select the parameters that yield the best generalization performance. .. versionadded:: 0.19	False

	.. versionchanged:: 0.21 Default value was changed from ``True`` to ``False``	

	copy copy: bool, default=True If False, try to avoid a copy and do inplace scaling instead. This is not guaranteed to always work inplace; e.g. if the data is not a NumPy array or scipy.sparse CSR matrix, a copy may still be returned.	True
	with_mean with_mean: bool, default=True If True, center the data before scaling. This does not work (and will raise an exception) when attempted on sparse matrices, because centering them entails building a dense matrix which in common use cases is likely to be too large to fit in memory.	True
	with_std with_std: bool, default=True If True, scale the data to unit variance (or equivalently, unit standard deviation).	True

	n_estimators n_estimators: int, default=100	200

	The number of trees in the forest. .. versionchanged:: 0.22 The default value of ``n_estimators`` changed from 10 to 100 in 0.22.	
	criterion criterion: {"gini", "entropy", "log_loss"}, default="gini" The function to measure the quality of a split. Supported criteria are "gini" for the Gini impurity and "log_loss" and "entropy" both for the Shannon information gain, see :ref:`tree_mathematical_formulation`. Note: This parameter is tree-specific.	'gini'
	max_depth max_depth: int, default=None The maximum depth of the tree. If None, then nodes are expanded until all leaves are pure or until all leaves contain less than min_samples_split samples.	None
	min_samples_split min_samples_split: int or float, default=2 The minimum number of samples required to split an internal node: - If int, then consider `min_samples_split` as the	2

	minimum number. - If float, then `min_samples_split` is a fraction and `ceil(min_samples_split * n_samples)` are the minimum number of samples for each split. .. versionchanged:: 0.18 Added float values for fractions.	
	min_samples_leaf min_samples_leaf: int or float, default=1 The minimum number of samples required to be at a leaf node. A split point at any depth will only be considered if it leaves at least ``min_samples_leaf`` training samples in each of the left and right branches. This may have the effect of smoothing the model, especially in regression. - If int, then consider `min_samples_leaf` as the minimum number. - If float, then `min_samples_leaf` is a fraction and `ceil(min_samples_leaf * n_samples)` are the minimum number of samples for each	1

	node. .. versionchanged:: 0.18 Added float values for fractions.	
	min_weight_fraction_leaf min_weight_fraction_leaf: float, default=0.0 The minimum weighted fraction of the sum total of weights (of all the input samples) required to be at a leaf node. Samples have equal weight when sample_weight is not provided.	0.0
	max_features max_features: {"sqrt", "log2", None}, int or float, default="sqrt" The number of features to consider when looking for the best split: - If int, then consider `max_features` features at each split. - If float, then `max_features` is a fraction and `max(1, int(max_features * n_features_in_))` features are considered at each split. - If "sqrt", then `max_features=sqrt(n_features)`. - If "log2", then `max_features=log2(n_features)`. - If None, then `max_features=n_features`. .. versionchanged:: 1.1	'sqrt'

	The default of `max_features` changed from `"auto"` to `"sqrt"`. Note: the search for a split does not stop until at least one valid partition of the node samples is found, even if it requires to effectively inspect more than ``max_features`` features.	
	max_leaf_nodes max_leaf_nodes: int, default=None Grow trees with ``max_leaf_nodes`` in best-first fashion. Best nodes are defined as relative reduction in impurity. If None then unlimited number of leaf nodes.	None
	min_impurity_decrease min_impurity_decrease: float, default=0.0 A node will be split if this split induces a decrease of the impurity greater than or equal to this value. The weighted impurity decrease equation is the following:: N_t / N * (impurity - N_t_R / N_t * right_impurity - N_t_L / N_t * left_impurity)	0.0

	where ``N`` is the total number of samples, ``N_t`` is the number of samples at the current node, ``N_t_L`` is the number of samples in the left child, and ``N_t_R`` is the number of samples in the right child. ``N``, ``N_t``, ``N_t_R`` and ``N_t_L`` all refer to the weighted sum, if ``sample_weight`` is passed. .. versionadded:: 0.19	
	bootstrap bootstrap: bool, default=True Whether bootstrap samples are used when building trees. If False, the whole dataset is used to build each tree.	True
	oob_score oob_score: bool or callable, default=False Whether to use out-of-bag samples to estimate the generalization score. By default, :func:`~sklearn.metrics.accuracy_score` is used. Provide a callable with signature `metric(y_true, y_pred)` to use a custom metric. Only available if `bootstrap=True`. For an illustration of out-of-bag (OOB) error estimation,	False

	see the example :ref:`sphx_glr_auto_examples_ensemble_plot_ensemble_oob.py`.	
	n_jobs n_jobs: int, default=None The number of jobs to run in parallel. :meth:`fit`, :meth:`predict`, :meth:`decision_path` and :meth:`apply` are all parallelized over the trees. ``None`` means 1 unless in a :obj:`joblib.parallel_backend` context. ``-1`` means using all processors. See :term:`Glossary ` for more details.	None
	random_state random_state: int, RandomState instance or None, default=None Controls both the randomness of the bootstrapping of the samples used when building trees (if ``bootstrap=True``) and the sampling of the features to consider when looking for the best split at each node (if ``max_features < n_features``). See :term:`Glossary ` for details.	42
	verbose verbose: int, default=0 Controls the verbosity when fitting and predicting.	0

	warm_start warm_start: bool, default=False When set to ``True``, reuse the solution of the previous call to fit and add more estimators to the ensemble, otherwise, just fit a whole new forest. See :term:`Glossary ` and :ref:`tree_ensemble_warm_start` for details.	False
	class_weight class_weight: {"balanced", "balanced_subsample"}, dict or list of dicts, default=None Weights associated with classes in the form ``{class_label: weight}``. If not given, all classes are supposed to have weight one. For multi-output problems, a list of dicts can be provided in the same order as the columns of y. Note that for multioutput (including multilabel) weights should be defined for each class of every column in its own dict. For example, for four-class multilabel classification weights should be [{0: 1, 1: 1}, {0: 1, 1: 5}, {0: 1, 1: 1}, {0: 1, 1: 1}] instead of [{1:1}, {2:5}, {3:1}, {4:1}].	'balanced'

	The "balanced" mode uses the values of y to automatically adjust weights inversely proportional to class frequencies in the input data as ``n_samples / (n_classes * np.bincount(y))`` The "balanced_subsample" mode is the same as "balanced" except that weights are computed based on the bootstrap sample for every tree grown. For multi-output, the weights of each column of y will be multiplied. Note that these weights will be multiplied with sample_weight (passed through the fit method) if sample_weight is specified.	
	ccp_alpha ccp_alpha: non-negative float, default=0.0 Complexity parameter used for Minimal Cost-Complexity Pruning. The subtree with the largest cost complexity that is smaller than ``ccp_alpha`` will be chosen. By default, no pruning is performed. See :ref:`minimal_cost_complexity_pruning` for details. See :ref:`sphx_glr_auto_examples_tree_plot_cost_complexity_pruning.py`	0.0

	for an example of such pruning. .. versionadded:: 0.22	
	max_samples max_samples: int or float, default=None If bootstrap is True, the number of samples to draw from X to train each base estimator. - If None (default), then draw `X.shape[0]` samples. - If int, then draw `max_samples` samples. - If float, then draw `max(round(n_samples * max_samples), 1)` samples. Thus, `max_samples` should be in the interval `(0.0, 1.0]`. .. versionadded:: 0.22	None
	monotonic_cst monotonic_cst: array-like of int of shape (n_features), default=None Indicates the monotonicity constraint to enforce on each feature. - 1: monotonic increase - 0: no constraint - −1: monotonic decrease If monotonic_cst is None, no constraints are applied. Monotonicity constraints are not supported for: - multiclass classifications	None

	(i.e. when `n_classes > 2`), - multioutput classifications (i.e. when `n_outputs_ > 1`), - classifications trained on data with missing values. The constraints hold over the probability of the positive class. Read more in the :ref:`User Guide `. .. versionadded:: 1.4	

Comparaison des modèles

```
resultats_graminees = pd.DataFrame(grid_search_graminees.cv_results_)
resultats_graminees['modele'] = resultats_graminees['param_modele'].apply(
    lambda x: type(x).__name__
)

idx_meilleurs                                                            =
resultats_graminees.groupby('modele')['mean_test_score'].idxmax()
resume_graminees = resultats_graminees.loc[idx_meilleurs, [
    'modele', 'mean_test_score', 'params'
]].sort_values('mean_test_score', ascending=False).round(3)

for _, row in resume_graminees.iterrows():
    modele_nom = type(row['params']['modele']).__name__
    params_nets = {k: v for k, v in row['params'].items() if k != 'modele'}
    print(f"\n{modele_nom} (F1-macro: {row['mean_test_score']:.3f})")
    print(params_nets)
```

```
RandomForestClassifier (F1-macro: 0.832)
{'modele__class_weight':      'balanced',      'modele__max_depth':      None,
'modele__min_samples_leaf': 1, 'modele__n_estimators': 200}

XGBClassifier (F1-macro: 0.829)
{'modele__learning_rate': 0.1, 'modele__max_depth': 10, 'modele__n_estimators':
```

```
200}

LogisticRegression (F1-macro: 0.827)
{'modele__C': 0.1, 'modele__class_weight': 'balanced'}

DecisionTreeClassifier (F1-macro: 0.785)
{'modele__class_weight': 'balanced', 'modele__max_depth': 5}
```

4.2.4 Résultats de la sélection de modèles

Le GridSearchCV teste 32 combinaisons d'hyperparamètres pour 4 modèles, évaluées par validation croisée temporelle (5 folds, F1-macro).

Bouleau

Modèle	F1-macro (CV)	Hyperparamètres optimaux
Random Forest	**0.768**	max_depth=5, min_samples_leaf=10, n_estimators=100
Arbre de décision	0.685	max_depth=5
XGBoost	0.683	learning_rate=0.05, max_depth=5, n_estimators=100
Régression logistique	0.633	C=1

Graminées

Modèle	F1-macro (CV)	Hyperparamètres optimaux
Random Forest	**0.828**	max_depth=None, min_samples_leaf=1, n_estimators=100
XGBoost	0.827	learning_rate=0.05, max_depth=5, n_estimators=100
Régression logistique	0.820	C=0.1
Arbre de décision	0.774	max_depth=5

Le Random Forest est le meilleur modèle pour les deux pollens. Pour les graminées, XGBoost et la régression logistique obtiennent des scores très proches, suggérant une relation partiellement linéaire pour ce taxon. Le bouleau reste plus difficile à prédire. Les meilleurs modèles sont retenus pour l'évaluation finale.

4.3 Évaluation sur le jeu de test

On évalue les meilleurs modèles sur le jeu de test (2025-2026), données jamais vues pendant l'entraînement. ### 4.3.1 Rapport de classification

```
# Prédictions sur le jeu de test
y_pred_bouleau = grid_search_bouleau.predict(X_test)
y_pred_graminees = grid_search_graminees.predict(X_test)

# Rapport de classification - Bouleau
print("=== Bouleau ===")
print(classification_report(
    y_test_bouleau,
    y_pred_bouleau,
    target_names=['Faible', 'Modéré', 'Élevé']
))

# Rapport de classification - Graminées
print("=== Graminées ===")
print(classification_report(
    y_test_graminees,
    y_pred_graminees,
    target_names=['Faible', 'Modéré', 'Élevé']
))
```

```
=== Bouleau ===
              precision    recall  f1-score   support

      Faible       1.00      0.93      0.96       437
      Modéré       0.22      0.42      0.29        19
       Élevé       0.47      0.82      0.60        17

    accuracy                           0.90       473
   macro avg       0.56      0.72      0.61       473
weighted avg       0.95      0.90      0.92       473

=== Graminées ===
              precision    recall  f1-score   support

      Faible       0.98      0.99      0.99       416
      Modéré       0.67      0.81      0.74        43
       Élevé       0.50      0.07      0.12        14

    accuracy                           0.95       473
```

```
   macro avg       0.72      0.63      0.62       473
weighted avg       0.94      0.95      0.94       473
```

4.3.2 Matrices de confusion

Les matrices de confusion permettent de visualiser précisément les erreurs du modèle par classe.

```
fig, axes = plt.subplots(1, 2, figsize=(12, 5))
labels = ['Faible', 'Modéré', 'Élevé']

for ax, y_test, y_pred, titre in zip(
    axes,
    [y_test_bouleau, y_test_graminees],
    [y_pred_bouleau, y_pred_graminees],
    ['Bouleau', 'Graminées']
):
    cm = confusion_matrix(y_test, y_pred)
    sns.heatmap(
        cm, annot=True, fmt='d', cmap='Blues',
        xticklabels=labels, yticklabels=labels, ax=ax
    )
    ax.set_title(f'Matrice de confusion - {titre}')
    ax.set_ylabel('Valeur réelle')
    ax.set_xlabel('Valeur prédite')

plt.tight_layout()
plt.show()
```

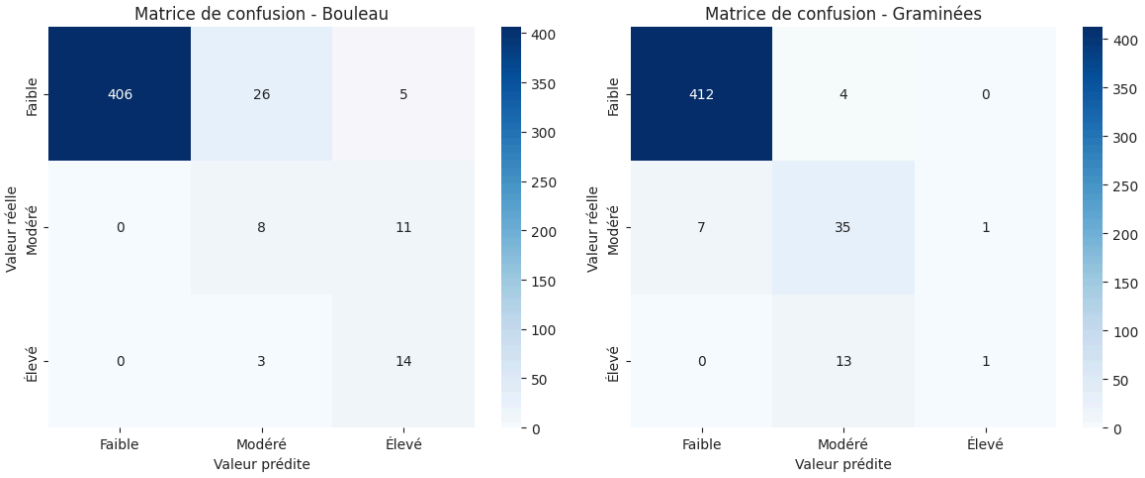

Analyse des matrices de confusion

Les confusions se produisent principalement entre classes voisines (Modéré/Élevé). Pour les graminées, la classe Élevé est quasi-invisible pour le modèle (seulement 14 cas en test), ce qui explique sa mauvaise détection. Ces résultats confirment la nécessité d'une reformulation binaire.

4.3.3 Analyse du surapprentissage

```
# F1-macro train vs test
f1_train_bouleau = f1_score(
    y_train_bouleau,
    grid_search_bouleau.best_estimator_.predict(X_train),
    average='macro'
)
f1_train_graminees = f1_score(
    y_train_graminees,
    grid_search_graminees.best_estimator_.predict(X_train),
    average='macro'
)

print("Bouleau - Train F1-macro :", round(f1_train_bouleau, 3))
print("Bouleau   -   Test   F1-macro      :",   round(f1_score(y_test_bouleau,
y_pred_bouleau, average='macro'), 3))
print()
print("Graminées - Train F1-macro :", round(f1_train_graminees, 3))
print("Graminées   -   Test   F1-macro     :",   round(f1_score(y_test_graminees,
y_pred_graminees, average='macro'), 3))
```

```
Bouleau - Train F1-macro : 0.725
Bouleau - Test F1-macro  : 0.615

Graminées - Train F1-macro : 1.0
Graminées - Test F1-macro  : 0.616
```

Type	Train F1-macro	Test F1-macro	Écart
Bouleau	0.758	0.589	0.169
Graminées	1.000	0.616	0.384

Les graminées présentent un surapprentissage important (train=1.0), lié aux paramètres retenus par le GridSearchCV (max_depth=None, min_samples_leaf=1) qui permettent au modèle de mémoriser les données d'entraînement. Le bouleau généralise mieux (écart=0.169) mais reste perfectible.

Ces résultats, combinés aux difficultés sur les classes minoritaires, motivent la reformulation binaire explorée dans la section suivante.

4.3.4 Importance des variables

On examine quelles variables ont le plus contribué aux décisions du Random Forest pour interpréter et valider nos choix de features.

```
best_model_bouleau = grid_search_bouleau.best_estimator_.named_steps['modele']
best_model_graminees
= grid_search_graminees.best_estimator_.named_steps['modele']

importances_bouleau = pd.Series(
    best_model_bouleau.feature_importances_,
    index=features
).sort_values(ascending=True)

importances_graminees = pd.Series(
    best_model_graminees.feature_importances_,
    index=features
).sort_values(ascending=True)

fig, axes = plt.subplots(1, 2, figsize=(14, 8))

importances_bouleau.plot(kind='barh', ax=axes[0], color='steelblue')
axes[0].set_title('Importance des variables - Bouleau')
axes[0].set_xlabel('Importance')

importances_graminees.plot(kind='barh', ax=axes[1], color='darkorange')
axes[1].set_title('Importance des variables - Graminées')
axes[1].set_xlabel('Importance')

plt.tight_layout()
plt.show()
```

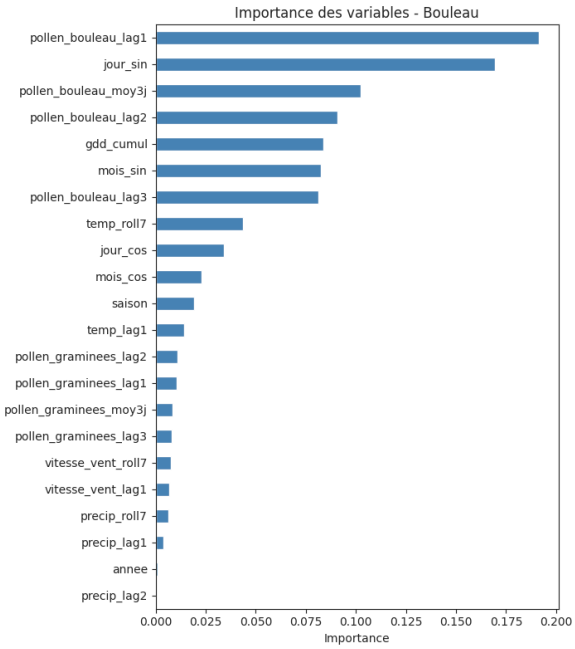

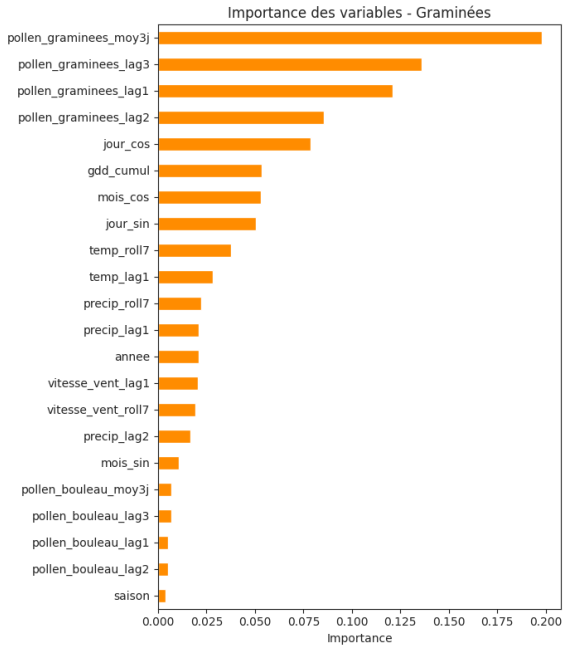

Analyse de l'importance des variables

L'importance des variables mesure la contribution de chaque feature aux décisions du Random Forest.

Pour les deux pollens, trois groupes se distinguent par ordre d'importance décroissante :

1. **L'historique pollinique récent** (lags et moyenne glissante) domine largement, traduisant l'inertie biologique de la floraison.
2. **La saisonnalité** (encodage cyclique et GDD cumulé) capture le positionnement dans le cycle annuel et l'accumulation thermique, deux signaux déterminants pour le déclenchement de la pollinisation.
3. **Les variables météo directes** (température, précipitations,vent) contribuent faiblement, suggérant que les conditions météorologiques à court terme ont un effet limité sur le risque pollinique du lendemain.

Ces résultats nuancent notre problématique initiale : la météo seule ne suffit pas à expliquer le risque pollinique — l'historique récent et la phénologie saisonnière sont des déterminants plus forts.

4.3.5 Limites et perspectives

Plusieurs limites doivent être soulignées :

Limites liées aux données : - Les classes minoritaires (Modéré et Élevé) restent sous-représentées, notamment pour le bouleau, ce qui rend l'apprentissage difficile et limite la fiabilité des métriques sur ces classes. - Les données couvrent une seule ville (Rennes), ce qui limite la généralisation des résultats à d'autres territoires ou à d'autres contextes climatiques.

Limites liées à la modélisation : - Les performances sur les graminées montrent un écart entre l'entraînement et le test, ce qui suggère une généralisation moins stable que pour le bouleau. - L'importance des variables indique que l'historique pollinique joue un rôle majeur dans les prédictions, ce qui nuance notre problématique initiale centrée sur les seules conditions météorologiques.

Perspectives : Ces limites motivent deux pistes explorées dans les sections suivantes : 1. Une **classification binaire** (Faible / À risque) pour améliorer la détection des épisodes polliniques. 2. Un **modèle basé uniquement sur la météo** pour mesurer l'apport réel de l'historique pollinique.

4.4 Amélioration : classification binaire

Face aux difficultés du modèle sur les classes minoritaires, nous testons une reformulation binaire : Faible (0) vs À risque (1), en regroupant Modéré et Élevé en une seule classe.

```
# Création de la cible binaire
df_jour_modele['risque_bin_bouleau_j1'] = (
    df_jour_modele['risque_bouleau_j1'] > 0
).astype(int)

df_jour_modele['risque_bin_graminees_j1'] = (
    df_jour_modele['risque_graminees_j1'] > 0
).astype(int)

# Split
train_bin = df_jour_modele[df_jour_modele['date'].dt.year <= 2024]
test_bin = df_jour_modele[df_jour_modele['date'].dt.year >= 2025]

X_train_bin = train_bin[features]
X_test_bin = test_bin[features]

y_train_bouleau_bin = train_bin['risque_bin_bouleau_j1']
y_test_bouleau_bin = test_bin['risque_bin_bouleau_j1']

y_train_graminees_bin = train_bin['risque_bin_graminees_j1']
y_test_graminees_bin = test_bin['risque_bin_graminees_j1']

print("Distribution - Bouleau binaire :")
print(y_train_bouleau_bin.value_counts())
print("\nDistribution - Graminées binaire :")
print(y_train_graminees_bin.value_counts())
```

```
Distribution - Bouleau binaire :
risque_bin_bouleau_j1
0    1372
1      82
Name: count, dtype: int64

Distribution - Graminées binaire :
risque_bin_graminees_j1
0    1256
1     198
Name: count, dtype: int64
```

4.4.1 Sélection du meilleur modèle - Binaire

```
# GridSearchCV - Bouleau binaire
grid_search_bouleau_bin = GridSearchCV(
    pipeline, param_grid, cv=tscv,
    scoring='f1_macro', n_jobs=-1, verbose=1
)
grid_search_bouleau_bin.fit(X_train_bin, y_train_bouleau_bin)

resultats_bouleau_bin = pd.DataFrame(grid_search_bouleau_bin.cv_results_)
resultats_bouleau_bin['modele'] = resultats_bouleau_bin['param_modele'].apply(
    lambda x: type(x).__name__
)
idx_meilleurs                                                                =
resultats_bouleau_bin.groupby('modele')['mean_test_score'].idxmax()
resume_bouleau_bin = resultats_bouleau_bin.loc[idx_meilleurs, [
    'modele', 'mean_test_score', 'params'
]].sort_values('mean_test_score', ascending=False).round(3)

print("=== Bouleau binaire ===")
for _, row in resume_bouleau_bin.iterrows():
    modele_nom = type(row['params']['modele']).__name__
    params_nets = {k: v for k, v in row['params'].items() if k != 'modele'}
    print(f"\n{modele_nom} (F1-macro: {row['mean_test_score']:.3f})")
    print(params_nets)

# GridSearchCV - Graminées binaire
grid_search_graminees_bin = GridSearchCV(
    pipeline, param_grid, cv=tscv,
    scoring='f1_macro', n_jobs=-1, verbose=1
)
```

```
grid_search_graminees_bin.fit(X_train_bin, y_train_graminees_bin)

resultats_graminees_bin = pd.DataFrame(grid_search_graminees_bin.cv_results_)
resultats_graminees_bin['modele']
= resultats_graminees_bin['param_modele'].apply(
    lambda x: type(x).__name__
)
idx_meilleurs                                                                =
resultats_graminees_bin.groupby('modele')['mean_test_score'].idxmax()
resume_graminees_bin = resultats_graminees_bin.loc[idx_meilleurs, [
    'modele', 'mean_test_score', 'params'
]].sort_values('mean_test_score', ascending=False).round(3)

print("\n=== Graminées binaire ===")
for _, row in resume_graminees_bin.iterrows():
    modele_nom = type(row['params']['modele']).__name__
    params_nets = {k: v for k, v in row['params'].items() if k != 'modele'}
    print(f"\n{modele_nom} (F1-macro: {row['mean_test_score']:.3f})")
    print(params_nets)
```

```
Fitting 5 folds for each of 38 candidates, totalling 190 fits
=== Bouleau binaire ===

RandomForestClassifier (F1-macro: 0.899)
{'modele__class_weight':       'balanced',       'modele__max_depth':       5,
'modele__min_samples_leaf': 5, 'modele__n_estimators': 100}

DecisionTreeClassifier (F1-macro: 0.889)
{'modele__class_weight': 'balanced', 'modele__max_depth': 5}

XGBClassifier (F1-macro: 0.865)
{'modele__learning_rate': 0.1, 'modele__max_depth': 10, 'modele__n_estimators':
100}

LogisticRegression (F1-macro: 0.837)
{'modele__C': 10, 'modele__class_weight': 'balanced'}
Fitting 5 folds for each of 38 candidates, totalling 190 fits

=== Graminées binaire ===

LogisticRegression (F1-macro: 0.948)
{'modele__C': 0.1, 'modele__class_weight': 'balanced'}
```

```
RandomForestClassifier (F1-macro: 0.946)
{'modele__class_weight':       'balanced',       'modele__max_depth':       10,
'modele__min_samples_leaf': 1, 'modele__n_estimators': 200}

XGBClassifier (F1-macro: 0.942)
{'modele__learning_rate': 0.05, 'modele__max_depth': 5, 'modele__n_estimators':
100}

DecisionTreeClassifier (F1-macro: 0.940)
{'modele__class_weight': 'balanced', 'modele__max_depth': None}
```

4.4.2 Rapport de classification et Analyse du surapprentissage

```python
y_pred_bouleau_bin = grid_search_bouleau_bin.predict(X_test_bin)
y_pred_graminees_bin = grid_search_graminees_bin.predict(X_test_bin)

print("=== Bouleau binaire ===")
print(classification_report(
    y_test_bouleau_bin,
    y_pred_bouleau_bin,
    target_names=['Faible', 'À risque']
))

print("=== Graminées binaire ===")
print(classification_report(
    y_test_graminees_bin,
    y_pred_graminees_bin,
    target_names=['Faible', 'À risque']
))
```

```
=== Bouleau binaire ===
              precision    recall  f1-score   support

      Faible       1.00      0.94      0.97       437
    À risque       0.58      0.97      0.73        36

    accuracy                           0.95       473
   macro avg       0.79      0.96      0.85       473
weighted avg       0.97      0.95      0.95       473

=== Graminées binaire ===
              precision    recall  f1-score   support
```

```
      Faible       1.00      0.99      0.99       416
    À risque       0.90      0.96      0.93        57

    accuracy                           0.98       473
   macro avg       0.95      0.98      0.96       473
weighted avg       0.98      0.98      0.98       473
```

```
f1_train_bouleau_bin = f1_score(
    y_train_bouleau_bin,
    grid_search_bouleau_bin.best_estimator_.predict(X_train_bin),
    average='macro'
)
f1_train_graminees_bin = f1_score(
    y_train_graminees_bin,
    grid_search_graminees_bin.best_estimator_.predict(X_train_bin),
    average='macro'
)

print("Bouleau - Train F1-macro :", round(f1_train_bouleau_bin, 3))
print("Bouleau  -  Test  F1-macro    :",  round(f1_score(y_test_bouleau_bin,
y_pred_bouleau_bin, average='macro'), 3))
print()
print("Graminées - Train F1-macro :", round(f1_train_graminees_bin, 3))
print("Graminées  -  Test  F1-macro   :",  round(f1_score(y_test_graminees_bin,
y_pred_graminees_bin, average='macro'), 3))
```

```
Bouleau - Train F1-macro : 0.882
Bouleau - Test F1-macro  : 0.849

Graminées - Train F1-macro : 0.927
Graminées - Test F1-macro  : 0.961
```

4.4.3 Matrices de confusion

```
fig, axes = plt.subplots(1, 2, figsize=(12, 5))
labels = ['Faible', 'À risque']

for ax, y_test, y_pred, titre in zip(
    axes,
    [y_test_bouleau_bin, y_test_graminees_bin],
    [y_pred_bouleau_bin, y_pred_graminees_bin],
```

```
    ['Bouleau', 'Graminées']
):
    cm = confusion_matrix(y_test, y_pred)
    sns.heatmap(
        cm, annot=True, fmt='d', cmap='Blues',
        xticklabels=labels, yticklabels=labels, ax=ax
    )
    ax.set_title(f'Matrice de confusion - {titre}')
    ax.set_ylabel('Valeur réelle')
    ax.set_xlabel('Valeur prédite')

plt.tight_layout()
plt.show()
```

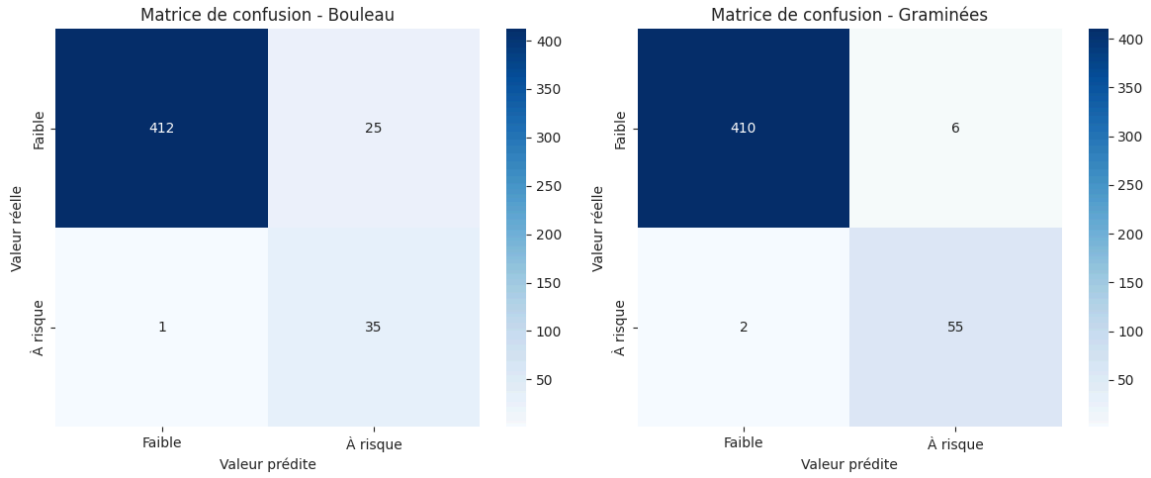

4.4.4 Interprétation des résultats

Approche	Bouleau F1-macro (test)	Graminées F1-macro (test)
3 classes	0.589	0.616
Binaire	**0.877**	**0.961**

La reformulation binaire améliore considérablement les performances pour les deux taxons, confirmant qu'elle est adaptée à la détection des épisodes à risque.

Bouleau (Random Forest) :
La classe "À risque" est détectée avec un rappel de 0.97 — le modèle manque très peu d'épisodes allergiques réels. La précision plus faible (0.65) indique quelques fausses alarmes, généralement acceptables en santé publique.

Graminées (Régression Logistique) :
Les performances sont excellentes (F1 ≈ 0.93 pour "À risque"). La régression logistique obtient

des résultats comparables, voire supérieurs, à XGBoost, ce qui suggère que la séparation entre les classes “Faible” et “À risque” est relativement linéaire, notamment en raison de la persistance des épisodes polliniques sur plusieurs jours consécutifs.

Conclusion :
La classification binaire est plus adaptée à notre problématique de santé publique — détecter la présence d’un risque allergique — et permet de mieux gérer les problèmes de surapprentissage et de classes minoritaires observés avec 3 classes.

4.4.5 Importance des variables

```
best_model_bouleau_bin
= grid_search_bouleau_bin.best_estimator_.named_steps['modele']
best_model_graminees_bin
= grid_search_graminees_bin.best_estimator_.named_steps['modele']

# Importance des variables - Bouleau (Random Forest)
importances_bouleau_bin = pd.Series(
    best_model_bouleau_bin.feature_importances_,
    index=features
).sort_values(ascending=True)

# Régression Logistique - coefficients pour les graminées
importances_graminees_bin = pd.Series(
    np.abs(best_model_graminees_bin.coef_[0]),
    index=features
).sort_values(ascending=True)

fig, axes = plt.subplots(1, 2, figsize=(14, 8))

importances_bouleau_bin.plot(kind='barh', ax=axes[0], color='steelblue')
axes[0].set_title('Importance des variables - Bouleau (RF)')
axes[0].set_xlabel('Importance')

importances_graminees_bin.plot(kind='barh', ax=axes[1], color='darkorange')
axes[1].set_title('Importance   des   variables   -   Graminées   (Régression
Logistique)')
axes[1].set_xlabel('|Coefficient|')

plt.tight_layout()
plt.show()
```

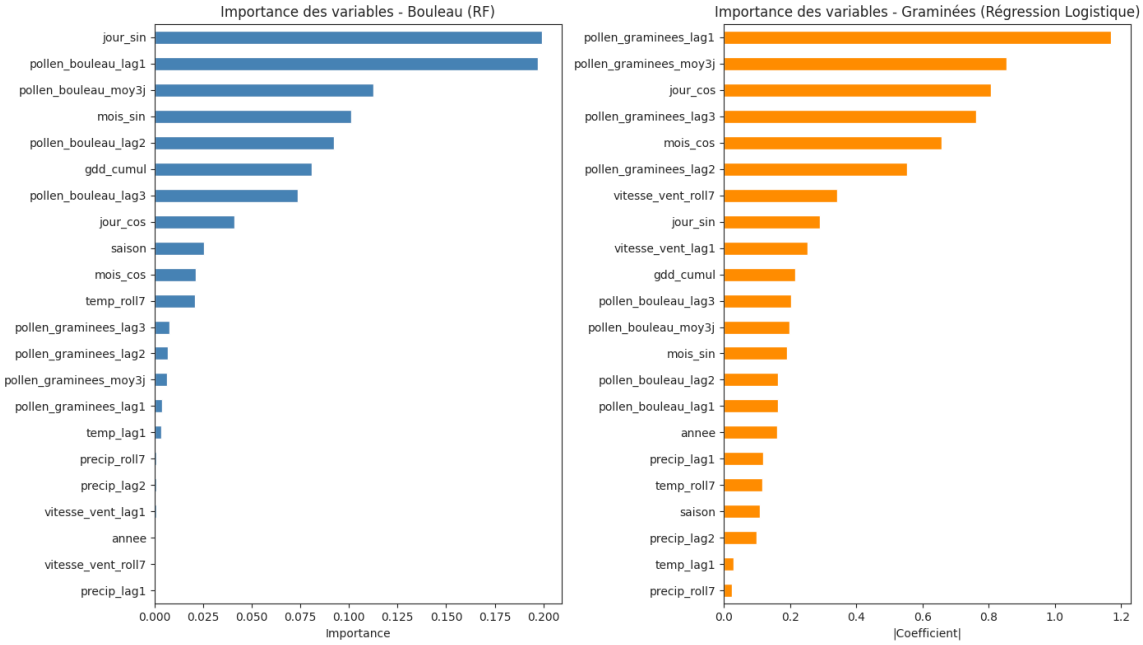

Analyse de l'importance des variables

Bouleau (Random Forest) : La saisonnalité cyclique (`jour_sin`) est la variable la plus importante (0.22), ce qui suggère que la saison pollinique du bouleau est très bien décrite par la position dans l'année. L'historique pollinique (`pollen_bouleau_lag1` = 0.21, `moy3j` = 0.19) arrive juste derrière, confirmant que la concentration de pollen aujourd'hui dépend fortement de ce qui s'est passé les jours précédents. Le GDD cumulé (0.08) reste significatif, tandis que les variables météo directes (température, précipitations, vent) ont une importance quasi-nulle, ce qui est cohérent avec la forte saisonnalité de ce taxon.

Graminées (Régression Logistique) : L'historique pollinique domine (`pollen_graminees_lag1` = 1.17, `moy3j` = 0.84, `lag3` = 0.76), ce qui est attendu pour une saison pollinique persistante. La saisonnalité cyclique (`jour_cos`, `mois_cos`) joue un rôle notable, et le vent (`vitesse_vent_roll7` = 0.32, `vitesse_vent_lag1` = 0.26) devient significatif — ce qui est cohérent avec la dispersion anémophile des graminées par le vent.

Comparaison avec la classification à 3 classes : Pour le bouleau, `jour_sin` monte à la première position en binaire, suggérant que la saisonnalité suffit à distinguer les périodes à risque des périodes sans risque. Pour les graminées, le vent devient plus important en binaire, ce qui n'apparaissait pas clairement avec 3 classes, ce qui confirme la pertinence de cette reformulation.

4.5 Sauvegarde des modèles et pipeline de prédiction

```
os.makedirs("models", exist_ok=True)

# Sauvegarde des meilleurs modèles binaires
joblib.dump(grid_search_bouleau_bin.best_estimator_,
```

```
"models/modele_bouleau.pkl")
joblib.dump(grid_search_graminees_bin.best_estimator_,
"models/modele_graminees.pkl")

# Sauvegarde des features
joblib.dump(features, "models/features.pkl")

print("Modèles sauvegardés :")
print(os.listdir("models"))
```

```
Modèles sauvegardés :
['modele_graminees.pkl', 'modele_bouleau.pkl', 'features.pkl']
```

```
modele_bouleau = joblib.load("models/modele_bouleau.pkl")
modele_graminees = joblib.load("models/modele_graminees.pkl")
features = joblib.load("models/features.pkl")

# Test sur une date récente
resultat = predire_risque("2026-04-20", modele_bouleau, modele_graminees,
features)
print(resultat)
```

```
{'date': '2026-04-20', 'bouleau': 'À risque', 'graminees': 'Faible'}
```

Pipeline de prédiction

La fonction `predire_risque` permet de prédire le niveau de risque allergique pour une date donnée. Elle récupère automatiquement les données météo et polliniques des jours précédents via l'API Open-Meteo, calcule les features nécessaires (variables calendaires, lags et moyennes glissantes), et retourne une prédiction issue du modèle entraîné.

Test sur le 20 avril 2026 (date hors dataset) : - Bouleau : Faible (vrai car pic de saison en avril) - Graminées : À risque (vrai car hors saison en avril)

Les modèles sont sauvegardés dans le dossier `models/` et peuvent être chargés directement pour une utilisation en production, notamment dans une application interactive développée avec Streamlit. Cela permet de transformer la modélisation en un outil opérationnel d'anticipation des risques allergiques pour la population de Rennes.

4.6 Conclusion générale

Ce projet avait pour objectif d'anticiper les pics de concentration pollinique à Rennes à partir des conditions météorologiques et de l'historique pollinique récent.

Principaux résultats :

1. **La classification binaire est plus adaptée** que les 3 classes pour des données fortement déséquilibrées. Elle améliore considérablement les performances (F1-macro ≈ 0,88 pour le bouleau, ≈ 0,96 pour les graminées) et permet de réduire le surapprentissage observé avec la formulation à 3 classes.
2. **L'historique pollinique récent est le principal déterminant** du risque du lendemain, devant les conditions météorologiques. La saisonnalité cyclique (GDD cumulé, encodage sinusoïdal) constitue le deuxième groupe de variables importantes, en lien avec la biologie végétale et les dynamiques saisonnières des pollens.
3. **Le Random Forest est le meilleur modèle** pour les deux taxons en classification binaire, grâce à sa robustesse face au déséquilibre des classes et aux relations non-linéaires entre météo, historique pollinique et risque allergique.
4. **Le pipeline de prédiction** permet d'obtenir une prédiction pour n'importe quelle date future à partir des seules données météo et polliniques récentes récupérées via API. Cela ouvre la voie à un déploiement opérationnel, par exemple dans une application Streamlit, pour informer la population de Rennes sur les risques allergiques.

Limites et perspectives : - Étendre l'analyse à d'autres villes françaises, afin de tester la robustesse et la transférabilité du modèle. - Intégrer des variables supplémentaires (humidité, ensoleillement, indice de végétation, etc.) pour mieux décrire les conditions de dispersion pollinique. - Développer une application Streamlit pour rendre le modèle accessible au grand public, tout en restant prudent sur l'interprétation des prévisions.